

基于 AI 的电网设备损伤检测与 SaaS 化设计

中期报告

冯宇捷

指导教师：侯金

2026 年 3 月 11 日

摘要

本报告为“基于 AI 的电网设备损伤检测与 SaaS 化设计”课题的中期总结。电力设备在运行中面临鸟巢、渗漏油、局部过热等典型损伤，传统人工巡检成本高、风险大且难以全覆盖。本项目旨在构建可扩展的 SaaS 化巡检平台：以多模态数据（无人机可见光、红外、传感器与历史记录）为输入，通过 AI 进行损伤检测与识别，并输出告警、工单与可视化分析。中期阶段已完成模块 A（鸟巢检测）端到端 PoC、模块 B（漏油检测）训练与部署、模块 C（红外高温检测）在 Flask 中的实现与接入（支持自定义温度区间、OCR 识别温区、水印干扰去除等）；报告总结了技术路线、已完成工作、存在问题与下一步计划。

目录

1 毕业设计（论文）概述	3
1.1 背景与目标	3
1.2 研究内容与技术路线	3
1.3 模块规划	3
2 毕业设计（论文）整体安排及进度	3
2.1 进度阶段划分	4
2.2 时间安排说明	4
3 毕业设计（论文）已完成的研究部分	4
3.1 模块 A：鸟巢检测 PoC	4
3.1.1 数据与增强	4
3.1.2 模型与训练配置	4
3.1.3 验证指标与训练曲线	5

3.2	模块 B: 漏油检测	7
3.2.1	数据准备	7
3.2.2	训练配置	7
3.2.3	验证指标与训练结果	7
3.2.4	与 Flask 服务集成	9
3.3	SaaS 部署与 Flask 微服务	9
3.3.1	功能概述	9
3.3.2	接口与运行方式	10
3.3.3	平台意义	10
3.4	模块 C (红外高温检测)	10
4	下一部分的工作安排	10
4.1	Track 1: SaaS 平台 (约第 4–10 周)	10
4.2	Track 2: 新模块扩展 (约第 11–18 周)	11
4.3	收尾与答辩 (约第 19–20 周)	11
5	毕业设计 (论文) 工作中存在的问题	11
5.1	泛化能力	11
5.2	技术选型讨论	11
5.3	局限与风险	12
6	参考文献	12

1 毕业设计（论文）概述

1.1 背景与目标

电力设备在运行中易出现鸟巢、渗漏油、局部过热等损伤，传统人工巡检效率低、风险高且难以全覆盖。本项目旨在构建可扩展的 SaaS 化巡检平台：以多模态数据（无人机可见光、红外、传感器与历史记录）为输入，通过 AI 进行损伤检测与识别，输出告警、工单与可视化分析；采用统一认证、多租户隔离与模型注册的 SaaS 设计，便于多部门共用同一套检测能力并与告警中心、工单系统对接。中期阶段已完成模块 A（鸟巢）端到端 PoC、模块 B（漏油）训练与部署、模块 C（红外高温）在 Flask 中的实现与接入。

1.2 研究内容与技术路线

采用“垂直切片、横向扩展”策略：先完成单模块从数据到部署的完整链路，再建设多模块注册与统一调度。技术路线：(1) **数据**：鸟巢 COCO、漏油 VOC/YOLO，脚本生成训练/验证集，增强与预处理在训练管线内完成；(2) **训练**：鸟巢 Mask R-CNN 实例分割，漏油 YOLOv8 目标检测，统一 AMP、学习率调度与 DataLoader 优化；(3) **部署**：Flask 微服务提供 REST API、批量上传与推理，鸟巢/漏油/红外三模块均已接入。鸟巢选 Mask R-CNN 以同时输出框与掩码便于与工单关联，漏油选 YOLOv8 兼顾速度与框级定位需求。

1.3 模块规划

- **Module A（鸟巢检测）**：已完成 PoC，验证整条管线（数据—训练—部署）。
- **Module B（漏油检测）**：已在 CSDN 数据集（train10-csdl）上完成 YOLOv8s 训练并接入 Flask；验证集最佳 mAP50 约 0.39，mAP50-95 约 0.26，详见第三部分。
- **Module C（红外高温检测）**：已实现并接入 `deploy/flask-service`，支持用户自定义告警温度区间、OCR 识别图像高低温刻度、水印与图例干扰去除，详见第三部分。

2 毕业设计（论文）整体安排及进度

整体安排及进度与开题报告一致，采用“双线并进”的阶段性规划（可参考《冯宇捷交大开题报告》中的进度表与甘特图）。各阶段划分如下。

2.1 进度阶段划分

- **第 1–4 周 (已完成):** 模块 A (鸟巢检测) PoC 实现: 数据准备、Mask R-CNN 训练、工程优化与 Flask 微服务部署, 完成从数据到可调用服务的垂直切片验证。
- **第 5–10 周:** Track 1 ——SaaS 平台建设。建立多租户后端、RBAC、任务编排与 AI 模型注册表 API, 并将 PoC 训练工具产品化。
- **第 11–18 周:** Track 2 ——新模块扩展。模块 C (红外) 已接入; 完成模块 B (漏油) 的完整训练与指标记录, 复用平台数据处理与训练能力, 巩固三模块在注册表与微服务目录中的集成。
- **第 19–20 周:** 最终集成与答辩。多模块与多用户端到端测试、系统优化、最终报告撰写与答辩准备。

2.2 时间安排说明

上述安排与开题答辩中的 Work Plan 一致: 先完成单模块垂直切片 (模块 A), 再横向扩展平台能力 (Track 1) 与新模块 (Track 2), 最后集中完成集成与论文。若开题报告中另有更细的周次或里程碑划分, 以开题报告为准进行对照与更新。

3 毕业设计 (论文) 已完成的研究部分

3.1 模块 A: 鸟巢检测 PoC

3.1.1 数据与增强

使用 COCO 格式鸟巢数据集, 共 54 张图像 (43 张训练、11 张验证), 每张图像包含鸟巢的边界框与实例分割多边形标注。采用确定性数据增强替代生成式方法 (如 Stable Diffusion 等), 原因在于前期尝试中发现生成式方法易产生物理不合理的伪影 (如在不锈钢件上生成锈迹、纹理错位), 影响模型对真实损伤的判别; 确定性增强在保证几何与光度合理性的前提下, 仍能显著增加样本多样性。具体包括: 自定义 Random IoU Crop (尺度 0.3–1.0), 迫使模型学习部分遮挡与多尺度目标; 光度扰动 (亮度、对比度等) 模拟现场光照变化; ResizeMax 与 PadSquare 统一宽高比并固定输入尺寸。上述流程均基于 `torchvision.transforms.v2` 实现, 与 PyTorch 2.x 及 DataLoader 兼容良好。

3.1.2 模型与训练配置

- 模型: Mask R-CNN (ResNet50 + FPN v2), 适用于实例分割与损伤区域精确定位。
- 输入尺寸: 512×512 , batch size 4, epochs 40 (支持 early stopping)。

- 优化器：AdamW，学习率 5×10^{-4} ，OneCycleLR 调度，混合精度（AMP）；单 epoch 约 27 秒，优化后 GPU 利用率约 70–85%。

3.1.3 验证指标与训练曲线

COCO 验证集上：bbox $AP_{50} = 1.000$ ，segm $AP_{50} = 1.000$ ，segm $AP_{75} = 0.919$ ， $AR@[0.50:0.95]$ 约 0.83；训练损失由约 1.41 降至 0.14，验证损失由约 0.65 降至 0.19，约在第 20 轮后趋于平稳，未观察到明显过拟合。PR 曲线在 $IoU=0.50$ 时精度接近 1.0， IoU 提高至 0.75、0.90 时略有下降，说明高 IoU 下对定位更敏感； IoU 分布右偏，得分阈值在 0.4–0.5 附近时 F1 较优，实际部署可据此调节置信度阈值以平衡漏检与误报。




图 1: 鸟巢检测训练/验证损失曲线；约第 20 轮后趋于平稳。




图 2: 鸟巢检测 bbox PR 曲线 (IoU 0.50/0.75/0.90)。




图 3: 鸟巢检测 bbox IoU 分布; 右偏表明定位质量较好。




图 4: 得分阈值与精确率/召回率/F1 关系 ($\text{IoU} \geq 0.5$); 阈值 0.4–0.5 附近 F1 较优。

3.2 模块 B: 漏油检测

3.2.1 数据准备

漏油数据来自两路：一是原始 VOC 格式数据集（约 103 张，含 XML 标注）；二是来自 CSDN 等渠道的 YOLO 格式数据。通过 `prepare_dataset.py` 支持三种模式：仅原始 VOC、仅 CSDN YOLO、以及合并两路数据（约 333 张，按约 8:2 划分训练/验证）。脚本将 VOC 框坐标转换为 YOLO 归一化格式，统一类别为 `oil_leak`，并生成数据集 YAML 供 YOLOv8 直接读取。本次报告采用的训练结果来自 `runs/detect/train10-csdn`，该实验使用 **CSDN 数据集** (`oil_leak_csdn.yaml`)，即仅使用 CSDN 渠道的 YOLO 格式数据。

3.2.2 训练配置

采用 YOLOv8s (`yolov8s.pt`)，单类别检测。`train10-csdn` 主要超参数：epochs 150、输入 640、batch 8、AdamW、cos 学习率、mosaic 0.3、mixup 0.05、cache 使用 RAM、patience 30、AMP 开启，固定随机种子 42。训练脚本为 `src/oil_leak/train.py`，可通过命令行指定 `--data`、`--epochs`、`--model` 等。

3.2.3 验证指标与训练结果

`train10-csdn` 共训练 123 个 epoch，验证集上最佳指标出现在第 93–94 轮附近：**precision(B)** 约 0.83、**recall(B)** 约 0.34、**mAP50(B)** 约 0.39、**mAP50-95(B)** 约 0.26。

训练损失 (box/cls/df1) 随 epoch 逐步下降并趋于稳定。图 5、图 6 与图 7 分别为验证集 PR 曲线、F1 曲线与归一化混淆矩阵；可将该次训练得到的最佳权重 (best.pt) 拷贝为 checkpoints/oil_leak_yolov8.pt 供 Flask 推理服务加载。




图 5: 漏油检测 (train10-csdcn) 验证集精确率-召回率曲线; IoU 阈值 0.5。




图 6: 漏油检测 (train10-csdcn) 验证集 F1 曲线; 不同置信度阈值下的 F1 分数。




图 7: 漏油检测 (train10-csdn) 验证集归一化混淆矩阵。

3.2.4 与 Flask 服务集成

Flask 推理服务已支持“漏油检测”模型：根据模型注册表中的 `weights_path` 加载 YOLOv8 权重，对上传图像执行推理，返回检测框坐标、置信度与可视化叠加图；若注册表路径缺失或文件不存在，服务会回退到 `checkpoints/oil_leak_yolov8.pt`，保证在权重尚未迁移到数据库时仍可正常使用。漏油模块与鸟巢模块共用同一套上传、推理与下载接口，仅根据用户选择的模型类型切换后端实现，便于后续在统一前端中扩展更多检测模块。

3.3 SaaS 部署与 Flask 微服务

3.3.1 功能概述

部署于 `deploy/flask-service`，提供以下能力：

- 批量图像上传与实时推理：用户可选择“鸟巢检测”“漏油检测”或“红外高温检测”等已注册模型，上传单张或多张图像，服务端按模型类型调用对应推理逻辑（Mask R-CNN、YOLOv8 或红外混合检测），返回 JSON 格式的检测框、置信度/温度及类别，并生成叠加了框与掩码的可视化图。
- 单张与 ZIP 结果下载：支持单张结果图下载及批量结果打包为 ZIP，便于现场巡检后离线查看与归档。
- 统计看板与图表：对历史推理任务与检测结果进行汇总展示，便于了解各模型调用情况与告警分布。

- 大图内存优化与错误处理：对大尺寸输入进行 `resize` 或分块策略，避免 OOM；接口层对异常进行捕获并返回明确错误信息，保证服务稳定可用。

3.3.2 接口与运行方式

请求流程为：用户通过 Web 页面上上传图片并选择模型 → 服务根据模型类型解析权重路径并执行推理 → 返回结构化结果与可视化图 URL。开发环境运行方式：`python run.py`，默认监听 `0.0.0.0:5000`；生产环境建议使用 Gunicorn 多进程（如 `gunicorn -w 4 wsgi:app`），以提升并发能力。

3.3.3 平台意义

作为“模型即服务”的落地，鸟巢、漏油与红外高温三模块均已通过统一接口对外提供推理能力；模型注册表与权重路径的配置化设计为多租户 SaaS、RBAC 与任务编排预留了架构空间。

3.4 模块 C（红外高温检测）

红外高温检测已在 `deploy/flask-service` 中实现并接入，与鸟巢、漏油共用同一套上传、推理与下载接口。实现位于 `app/services/model_service.py` 与 `app/routes/inference.py`，采用 OCR 与像素映射的混合方案，无需单独训练深度学习模型即可对红外热力图进行高温区域检测。

主要功能包括：(1) 用户自定义告警温度区间：前端或 API 传入告警温度阈值（默认 50°C ），服务据此将灰度映射为温度并筛选超过阈值的热点区域。(2) OCR 识别高低温刻度：使用 EasyOCR 对红外图像进行文字检测与识别，从图例或刻度区域解析出图像对应的最高温与最低温，用于将像素灰度线性映射到温度值，并对常见 OCR 误识别做启发式修正。(3) 去除水印与图例干扰：通过边框水印掩码构建函数检测并掩码图像边缘的白色水印与 Logo 区域，避免被误判为高温热点；通过 OCR 文本区域掩码排除图例与刻度数字，减少误检。输出包括热点框、每个热点的温度值、全图最大读取温度与最大热点温度，以及叠加了框与温度标注的可视化图。

4 下一部分的工作安排

4.1 Track 1: SaaS 平台（约第 4–10 周）

- 实现多租户后端、RBAC 与任务编排：包括用户/角色/权限的数据模型与接口设计、任务队列（如 Celery 或内存队列）与任务状态查询，使多用户可并发提交检测任务并查看结果。

- 定义 AI 模型注册表 API: 统一模型的注册、查询、启用/停用及权重路径管理, 便于前端与调度层按名称或类型选择模型, 并为后续模型版本与 A/B 测试留接口。
- 将 PoC 训练工具 (增强、日志等) 产品化: 把当前脚本中的增强配置、训练日志与 checkpoint 管理抽象为可配置、可复用的工具, 供漏油与红外模块共用, 减少重复开发。

4.2 Track 2: 新模块扩展 (约第 11–18 周)

- 推进模块 B (漏油) 的完整实验与巩固模块 C (红外): 完成漏油在合并数据集上的完整训练与验证指标记录并更新注册表; 红外模块已上线, 后续可做鲁棒性优化与多设备红外图适配。
- 复用平台的数据处理与训练能力: 新模块尽量复用 `prepare_dataset`、训练脚本与部署管线, 仅替换数据路径与模型类型, 降低维护成本。
- 将新模块接入注册表与微服务目录: 在数据库与前端中增加新模型条目, 确保任务路由与推理逻辑能正确识别并调用。

4.3 收尾与答辩 (约第 19–20 周)

最终集成、系统测试与报告撰写: 对多模块、多用户场景做端到端测试, 整理实验数据与截图, 完成最终报告与答辩材料; 预期产出包括可演示的鸟巢/漏油/红外三模块 SaaS 原型、符合要求的书面报告与答辩展示。

5 毕业设计 (论文) 工作中存在的问题

5.1 泛化能力

当前鸟巢验证集上 $AP_{50}=1.0$ 、IoU 接近 1.0, 与训练场景高度一致, 说明在“与训练同分布”的验证集上模型表现良好。但在实际复杂场景 (雾霾、逆光、新杆型、不同季节与地域) 下, 性能可能明显下降。因此, 数据增强、负样本构建与多场景评估是平台级共性需求: 后续计划引入更多跨场景数据或留出一批“未参与训练”的现场数据做泛化测试, 并在漏油与红外模块中同样重视负样本与困难样本设计, 避免仅在小规模、同分布数据上追求过高指标而忽视真实场景鲁棒性。

5.2 技术选型讨论

- SaaS 后端: 是优先做功能完整的原型 (如简易 RBAC、任务队列与多租户隔离的雏形) 还是从第一天就投入生产级认证 (如 OAuth2、审计日志), 需结合课题时

间与答辩目标权衡；当前倾向先完成可演示的多模型、多任务原型，再视时间补充权限与审计。

- **漏油模块**：漏油检测目前采用 YOLOv8 框级检测，已能满足“有无漏油与大致位置”的需求；若业务后续要求精确到油渍边界（如面积统计、趋势对比），可评估引入语义分割（如 U-Net）或与实例分割联合，届时需补充像素级标注数据。
- **红外模块**：红外高温检测已作为独立模块接入，支持自定义告警温度与 OCR 温区识别；后续可考虑与可见光融合做多模态分析（如 RGB+ 热力图联合输入），需结合现场数据与运维需求再定接口与模型结构。

5.3 局限与风险

当前数据规模仍偏小（鸟巢 54 张、漏油合并后约 333 张），标注质量与一致性对结果影响较大；部署环境上，Flask 单机多进程可支撑中小并发，若需更高并发或分布式推理，需进一步引入队列与 worker 池。这些将在后续阶段通过数据扩充与架构迭代逐步缓解。

6 参考文献

1. He K, Gkioxari G, Dollár P, et al. Mask R-CNN[C]//ICCV, 2017.
2. Lin T Y, Maire M, Belongie S, et al. Microsoft COCO: Common objects in context[C]//ECCV, 2014.
3. Jocher G, et al. Ultralytics YOLOv8. github.com/ultralytics/ultralytics
4. Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//CVPR, 2016.
5. PyTorch. torchvision.models.detection. pytorch.org/vision
6. Flask. Web framework. flask.palletsprojects.com